

Машинное обучение


Методы понижения размерности

Маничева А.С.,
доцент, канд. техн. наук

Постановка задачи по сокращению размерности

Сокращение или понижение размерности – задача обучения без учителя.

Суть задачи понижения размерности – имея данные с большим количеством признаков (столбцов), надо преобразовать их в новую таблицу с меньшим количеством признаков (столбцов). Количество объектов (строк) при этом останется неизменным.



Зачем использовать сокращение размерности

- ▶ Сжатие данных
- ▶ Ускорение предсказаний
- ▶ Визуализация данных
- ▶ Более компактное и «правильное» описание объектов
- ▶ Повышение интерпретируемости

Методы выделения новых признаков

Методы выделения новых признаков – методы, создающие новые столбцы, которые вычисляются по формулам, зависящим от имеющихся в данных столбцов.

Новые признаки могут быть сложно интерпретируемыми, но могут содержать гораздо больше информации об объектах, чем любой набор исходных признаков того же количества.

Методы снижения размерности пространства признаков:

- ▶ **метод главных компонент** (Principal Component Analysis, PCA)
- ▶ **топологический анализ данных** (Topological data analysis, TDA)
- ▶ **UMAP** (Uniform Manifold Approximation and Projection)

Топологический анализ данных

Топологический анализ данных (Topological data analysis, TDA) – это современное и быстро развивающееся направление анализа данных и компьютерного зрения, которое обеспечивает основу для анализа данных, у объектов которых помимо собственных признаковых описаний существуют некоторые взаимосвязи, описывающие взаимодействие подмножеств этих объектов.

Основные вопросы:

- ▶ Как из низкоразмерных представлений получать структуры высоких размерностей.
- ▶ Как дискретные единицы складываются в глобальные структуры.

Топологический анализ данных за счет использования методов из топологии и геометрии обеспечивает уменьшение размерности и устойчивость к шуму.

Метод главных компонент

Метод главных компонент (principal component analysis, PCA) – метод, который осуществляет вращение данных с тем, чтобы преобразованные признаки не коррелировали между собой. Часто это вращение сопровождается выбором подмножества новых признаков в зависимости от их важности с точки зрения интерпретации данных.


Допущения в задача снижения размерности:

- ▶ Переменные сколько-то существенно различны по информативности и мы принципиально можем выкидывать часть из них без критического ущерба для итоговой информации.
- ▶ Какая-то часть переменных зависима между собой и может быть заменена на некоторый интегральный показатель на основе их комбинации (обычно линейной).

Метод главных компонент (PCA)

Главные компоненты (principal components) – направления, найденные с помощью PCA.

Максимально возможное количество главных компонент равно количеству исходных признаков.



Метод главных компонент (PCA)

Пусть N – число исследуемых объектов; n – число признаков; матрица Y порядка $n \times N$ – совокупность всех N наблюдаемых значений всех параметров n после нормализации.

Необходимо описать набор признаков m числом главных компонент $m << n$, обеспечивающих долю дисперсии $\gamma \geq 0,95$ и сформировать интегральный показатель оптимальности на основе матрицы A весовых коэффициентов, учитывающих тесноту связи между исходными признаками и главными компонентами:

$$Y = A \cdot F,$$

где матрица F включает совокупность всех N полученных значений всех m главных компонент. Или в развернутом матричном виде:

$$\begin{pmatrix} y_{11} & y_{12} & \dots & y_{1N} \\ y_{21} & y_{22} & \dots & y_{2N} \\ \dots & \dots & \dots & \dots \\ y_{n1} & y_{n2} & \dots & y_{nN} \end{pmatrix} = \begin{pmatrix} a_{11} & a_{12} & \dots & a_{1N} \\ a_{21} & a_{22} & \dots & a_{2N} \\ \dots & \dots & \dots & \dots \\ a_{n1} & a_{n2} & \dots & a_{nN} \end{pmatrix} \cdot \begin{pmatrix} f_{11} & f_{12} & \dots & f_{1N} \\ f_{21} & f_{22} & \dots & f_{2N} \\ \dots & \dots & \dots & \dots \\ f_{m1} & f_{m2} & \dots & f_{mN} \end{pmatrix} \quad (1)$$

Задача сводится к определению матрицы A .

Метод главных компонент (PCA)

Связь между главными компонентами и коэффициентами корреляции для объекта i :

$$y_{ji} = a_{j1}f_{1i} + a_{j2}f_{2i} + \dots + a_{jn}f_{ni}, \quad i=1,..,N, \quad (2)$$

где y_{ji} – нормированное значение j -го признака для i -го объекта;
 f_{1i} – значение первой главной компоненты для i -го объекта.

Полная дисперсия статистического признака выражается через дисперсию главных компонент:

$$\begin{aligned} \sigma_o^2 &= \frac{1}{N} \sum_{i=1}^N y_{ji}^2 = \frac{1}{N} \left[a_{j1}^2 \sum_{i=1}^N f_{1i}^2 + a_{j2}^2 \sum_{i=1}^N f_{2i}^2 + \dots + a_{jn}^2 \sum_{i=1}^N f_{ni}^2 + \right. \\ &\quad \left. + 2 \left(a_{j1}a_{j2} \sum_{i=1}^N f_{1i}f_{2i} + a_{j1}a_{j3} \sum_{i=1}^N f_{1i}f_{3i} + \dots + a_{j(n-1)}a_{jn} \sum_{i=1}^N f_{(n-1)i}f_{ni} \right) \right]. \end{aligned} \quad (3)$$

Выражение 3 упрощается до (4):

$$\sigma_j^2 = a_{j1}^2 + a_{j2}^2 + \dots + a_{jn}^2 = 1. \quad (4)$$

Слева – полная дисперсия, а справа – доли полной дисперсии, относящиеся к соответствующим главным компонентам.

Метод главных компонент (PCA)

Полный вклад r -го фактора в дисперсию всех n признаков определяет ту долю общей дисперсии, которую данная главная компонента объясняет. Этот вклад вычисляется как:

$$V_r = \sum_{j=1}^n a_{jr}^2, \quad (5)$$

где j – индекс признака (показателя коммерческой эффективности); r – индекс главной компоненты.

При помощи m первых (наиболее весомых, обеспечивающих долю дисперсии $\gamma \geq 0,95$) главных компонент можно объяснить основную часть суммарной дисперсии и эти компоненты используются в дальнейшей работе.

Метод главных компонент (PCA)

Применение PCA:

- ▶ **визуализация данных;**
- ▶ **сокращение размерности в моделях;**
- ▶ **выделение скрытых факторов;**
- ▶ **фильтр "шума".**

UMAP

Uniform Manifold Approximation and Projection (UMAP) – это новый алгоритм машинного обучения, выполняющий нелинейное снижение размерности.

Принцип работы метода:


- 1) выполняется построение взвешенного графа путем соединения ребрами только тех объектов, которые являются ближайшими соседями;
- 2) создается граф в низкоразмерном пространстве и приближается к исходному.

Полученное множество из ребер определяет новое расположение объектов и, соответственно, низкоразмерное отображение исходного пространства.

UMAP

Достоинства:

- ▶ отсутствие ограничений на размерность исходного пространства признаков, которое необходимо уменьшить,
- ▶ быстрее и более вычислительно эффективен, чем существующие методы,
- ▶ лучше справляется с задачей переноса глобальной структуры данных в новое, уменьшенное пространство.



Спасибо за внимание!